

Classificação da Qualidade de Vinhos com **Machine Learning**

Grupo

Frederico Sousa Ribeiro | Júlio César do Amaral Francisco

Como antecipar a qualidade de um vinho usando dados da produção?

FIAP

- Qualidade do vinho costuma ser avaliada por especialistas;
- O processo pode ser subjetivo e demandar tempo;
- Dados físico-químicos podem apoiar decisões no processo produtivo.



Grupo

Frederico Sousa Ribeiro | Júlio César do Amaral Francisco

Transformamos a nota de qualidade em uma decisão de negócio

FIAP

Números principais:

- 1.143 amostras
- 13 colunas na base original
- 11 características físico-químicas
- Nota original de qualidade: 3 a 8



Regra de Negócio:

Nota **maior ou igual a 7** ->
Alta Qualidade


Nota **menor que 7** ->
Baixa/Média Qualidade

Grupo

Frederico Sousa Ribeiro | Júlio César do Amaral Francisco

A maior parte dos vinhos está concentrada em notas intermediárias

FIAP



82,7%
da base são
notas 5 e 6

13,5%
representa
alta qualidade

A base tem poucos exemplos de vinhos de alta qualidade, o que torna essa classe mais difícil de identificar.

Grupo

Frederico Sousa Ribeiro | Júlio César do Amaral Francisco


Algumas características se destacam na relação com a qualidade

Teor alcoólico: maior associação **positiva** com qualidade **+0,485**

Acidez volátil: maior associação **negativa** com qualidade **-0,407**

- Sulfatos e ácido cítrico também aparecem associados **positivamente**;
- Densidade e dióxido de enxofre total aparecem associados **negativamente**.

Os dados indicam quais características merecem maior atenção no acompanhamento da qualidade.



Grupo

A base foi preparada para evitar distorções no modelo

A preparação buscou **garantir** uma comparação mais **justa** entre os modelos, **sem inflar artificialmente** o desempenho.



Pontos principais

- 1.143 registros na base original;
- 125 registros repetidos removidos;
- 1.018 registros utilizados na modelagem;
- Valores fora do padrão foram identificados e mantidos, pois não havia evidência de erro.

Grupo

Random Forest apresentou o melhor equilíbrio entre acerto e confiabilidade

O modelo combinou alto acerto geral com o melhor resultado consolidado para identificar vinhos de alta qualidade.

MODELO RECOMENDADO

Random Forest

90,7% Acerto Geral

72,2% Confiabilidade

57,8% F1-Score

POR QUE VENCEU?

- Maior F1-score: 57,8%
- Acurácia: 90,7%
- Precisão: 72,2%
- Melhor equilíbrio entre erros

Regressão Logística

Resultado consistente, porém inferior

- Acerto geral: 89,7%;
- Precisão: 65,0%;
- Identificação de alta Qualidade: 33,3%
- F1-score: 55,3%.

Regressão Logística Balanceada

Identifica mais casos, mas gera falsos alertas

- Acerto geral: 78,4%;
- Precisão: 35,6%;
- Identificação de alta Qualidade: 77,8%
- F1-score: 48,8%.

Random Forest Balanceado

Seletivo, porém deixa muitos casos pasar

- Acerto geral: 90,7%;
- Precisão: 90,0%;
- Identificação de alta Qualidade: 33,3%
- F1-score: 48,6%.

Grupo

O modelo pode apoiar a padronização da qualidade

Conclusão executiva e aplicação para o negócio



MODELO SELECIONADO

Random Forest sem balanceamento

90,7% Acurácia

Melhor equilíbrio geral entre desempenho e confiabilidade



VARIÁVEIS MAIS RELEVANTES

1. Teor alcoólico
2. Acidez volátil
3. Sulfatos
4. Densidade
5. Ácido cítrico

As variáveis representam os principais sinais utilizados pelo modelo para apoiar a classificação.



APLICAÇÃO PARA O NEGÓCIO

O modelo pode apoiar produtores e especialistas na priorização de análises e no controle de qualidade, mas não substitui a avaliação técnica e sensorial.

Uso recomendado: apoio à decisão e padronização do acompanhamento da qualidade.

Grupo

OBRIGADO!

Grupo

Frederico Sousa Ribeiro | Júlio César do Amaral Francisco